

ANÁLISIS DE RENDIMIENTO EN EL FÚTBOL EUROPEO

Pipeline ETL · Análisis Exploratorio · Cubo Dimensional con PySpark

Asignatura: Introducción a los Sistemas Big Data — Valor de la Información

Universidad Francisco de Vitoria · Curso 2025–2026

Integrantes: Raúl Moreno, Daniel Vaquero, Íñigo Val y Javier Ruiz

Mayo 2026

Índice

1. Introducción y preguntas de negocio	3
2. Orígenes y extracción de datos	4
3. Diagrama de flujo del pipeline	6
4. Análisis inicial de calidad	7
5. ETL — Transformación y limpieza	9
6. EDA Final — Análisis exploratorio con gráficas	11
7. Modelo dimensional — Diagrama en estrella	16
8. Carga en base de datos SQL	17
9. Repositorio GitHub	19
10. Cuaderno PySpark — Cubo Dimensional OLAP	20
11. Conclusiones y escalabilidad	23
12. Uso de IA y bibliografía	25

1. Introducción y Preguntas de Negocio

El fútbol profesional genera cada temporada millones de datos: resultados, estadísticas de partido, expected goals, valoraciones de jugadores y movimientos de mercado. Sin embargo, la mayor parte del análisis público se limita a tablas de clasificación y goles marcados, ignorando las métricas subyacentes que explican por qué un equipo gana o pierde de forma sistemática.

Este proyecto construye un pipeline ETL completamente automatizado que integra tres fuentes heterogéneas de datos y las transforma en un modelo dimensional analítico. El objetivo no es predecir el resultado de un partido concreto, sino responder preguntas estructurales sobre la relación entre el talento individual (medido por EA Sports FC 24), el rendimiento colectivo real (partidos de LaLiga) y las métricas avanzadas de calidad de juego (xG de Understat).

Objetivo general

Construir un pipeline ETL completamente automatizado, documentado y reproducible que transforme datos brutos de tres fuentes heterogéneas en un modelo dimensional con cuatro dimensiones, almacenado en SQLite, exportado a GitHub y analizado con PySpark en Google Colab para responder a preguntas de negocio sobre el rendimiento individual, colectivo y de mercado en el fútbol profesional europeo.

Preguntas de negocio que guían el análisis

- **Q1:** ¿Cuál es la correlación entre el overall FIFA de los jugadores de un equipo y su posición final en la tabla de LaLiga?
- **Q2:** ¿Qué equipos generan más xG del que su valoración FIFA media sugeriría? ¿Son esos equipos más eficientes?
- **Q3:** ¿Cómo evoluciona el rendimiento de un equipo en la temporada siguiente a una gran inversión en fichajes?
- **Q4:** ¿Qué atributos FIFA predicen mejor el rendimiento real (goles, asistencias, minutos jugados)?
- **Q5:** ¿Qué ocurre cuando un jugador con overall alto abandona un equipo? ¿Cae el rendimiento colectivo esa temporada?

2. Orígenes y Extracción de Datos

El proyecto integra tres fuentes con formatos, granularidades y naturalezas distintas. Esta heterogeneidad es precisamente lo que hace el análisis interesante: ninguna fuente por sí sola puede responder las preguntas de negocio formuladas.

Fuente 1 — Football-Data.co.uk (estadísticas de partidos, LaLiga)

Campo	Descripción
Nombre	football-data.co.uk — LaLiga
Formato	CSV descarga directa, sin autenticación
Registros	380 partidos × 5 temporadas = 1.900 partidos
Variables	105 columnas (119 en la última temporada)
Temporadas	2020-21, 2021-22, 2022-23, 2023-24, 2024-25
Frecuencia	Estática — datos históricos cerrados por temporada
Licencia	Open Data — uso libre para fines académicos

Fuente 2 — Understat (xG y métricas avanzadas por equipo)

Campo	Descripción
Nombre	Understat — LaLiga Expected Goals
Formato	JSON vía scraping con understatapi (Python)
Registros	380 filas por temporada × 5 = 1.900 registros
Variables clave	xGhome, xGaway, xGAhome, xGAaway, npxG, xPTS
Temporadas	2020-21 a 2024-25
Licencia	Datos públicos, uso académico declarado

Fuente 3 — EA Sports FC 24 Players (Kaggle)

Campo	Descripción
Nombre	EA Sports FC 24 Complete Player Dataset
Formato	CSV descarga directa desde Kaggle
Registros originales	18.500 jugadores, 110 columnas de atributos
Variables clave	overall, potential, pace, shooting, passing, defending, value_eur, wage_eur
Temporada equivalente	EA FC 24 ≡ temporada 2023-24
Licencia	CC0 Public Domain

3. Diagrama de Flujo del Pipeline

El pipeline sigue una arquitectura lineal de seis etapas. Cada etapa tiene un artefacto de salida claro y actualiza el fichero de tracking (pipeline_tracking.json) antes de pasar a la siguiente. Este diseño garantiza trazabilidad completa y permite reanudar el pipeline desde cualquier punto en caso de fallo.

ETAPA 1 — EXTRACCIÓN	F1: 5 CSVs de football-data.co.uk → data/raw/SP1_3..7.csv F2: JSON Understat API → data/raw/understat_20-25.json F3: CSV Kaggle EA FC 24 → data/raw/eafc24_players.csv
ETAPA 2 — CALIDAD INICIAL	Análisis de nulos, blancos, duplicados, tipos y outliers por fuente. Output: pipeline_tracking.json fase QUALITY
ETAPA 3 — ETL (T01-T10)	Deduplicación · Nulos/Blancos · Tipos · Fechas ISO-8601 · Normalización texto · Outliers IQR · Seudonimización PII · Validación referencial Output: data/processed/dataset_limpio.csv
ETAPA 4 — MODELO ESTRELLA	Construcción de FACT_RENDIMIENTO + 4 dimensiones: DIM_JUGADOR, DIM_EQUIPO, DIM_TIEMPO, DIM_COMPETICION
ETAPA 5 — CARGA SQL	DDL SQLite · Dimensiones primero, FACT después · Verificación COUNT(*) · Exportación a data/final/ · Push a GitHub
ETAPA 6 — CUBO OLAP	PySpark en Google Colab · SparkSession · JOIN FACT ↔ 4 Dims · cube/rollup/spark.sql · 5 preguntas de negocio · Gráficas exportadas

4. Análisis Inicial de Calidad

Antes de aplicar ninguna transformación, cada fuente se analiza por separado para establecer la línea base que justifica las decisiones de limpieza posteriores. Los resultados se registran automáticamente en pipeline_tracking.json.

Fuente	Registros	Variables	Nulos (%)	Duplicados	Outliers detectados
F1 SP1_3.csv	380	105	0.01 %	0	3 cuotas extremas
F1 SP1_4.csv	380	105	0.05 %	0	2
F1 SP1_5.csv	380	105	0.00 %	0	1
F1 SP1_6.csv	380	105	3.02 %	0	4
F1 SP1_7.csv	380	119	3.46 %	0	5
F2 Understat	1.900	18	0.80 %	0	2 xG extremos
F3 EA FC 24	18.534	110	4.20 %	847	183 valores extremos
TOTAL / MEDIA	22.334	—	1.65 %	847	200

Interpretación por fuente

F1 — Football-Data: Calidad muy alta en las tres primeras temporadas (nulos < 0.05 %). Los archivos SP1_6 y SP1_7 tienen nulos ~3 %, concentrados en columnas de casas de apuestas minoritarias no relevantes para el análisis. Las variables críticas (FTHG, FTAG, FTR, HS, AS, HST, AST) no tienen nulos en ninguna temporada.

F2 — Understat: El 0.80 % de nulos corresponde principalmente a partidos aplazados donde el scraper no recogió el dato de xG. Se imputan con la media del equipo en esa temporada.

F3 — EA FC 24: Es la fuente con más irregularidades. El 4.20 % de nulos se concentra en atributos de porteros (pace, shooting) que no aplican al rol. Los 847 duplicados son versiones dobles de jugadores (base + especial) y se resuelven conservando la fila con mayor overall. Los 183 outliers en value_eur y wage_eur son jugadores de élite — se conservan porque son informativamente relevantes.

5. ETL — Transformación y Limpieza

El pipeline ETL está implementado íntegramente en Python con módulos independientes por fase (extract.py, clean.py, transform.py, load.py, tracker.py), orquestados por pipeline.py. Cada transformación queda registrada en pipeline_tracking.json con timestamp, registros de entrada/salida y registros descartados.

Código	Transformación	Acción aplicada	Resultado
T01	Deduplicación	dropDuplicates sobre F3 por player_id, conservando max(overall)	847 filas eliminadas de F3
T02	Tratamiento nulos	F3 porteros → imputar 0 en atributos de campo; F2 xG faltante → media del equipo/temporada	0 registros descartados
T03	Eliminación blancos	strip() en columnas de texto, reemplazar vacíos por NaN	12 blancos corregidos en F3
T04	Casteo de tipos	Date→DateType; cuotas→FloatType; goles/atributos→IntegerType; overall→IntegerType	Tipos correctos en todas las columnas
T05	Normalización fechas	to_date(col, 'dd/MM/yyyy') → formato ISO-8601	1.900 fechas normalizadas
T06	Normalización texto	Lowercase + eliminación de acentos en nombres de equipos y jugadores	Consistencia entre F1/F2/F3
T07	Corrección rangos	overall entre 1-99; value_eur ≥ 0; goles ≥ 0	0 registros fuera de rango
T08	Outliers IQR	IQR en value_eur y wage_eur → documentados, no eliminados	183 outliers marcados con flag
T09	Seudonimización PII	SHA-256 sobre short_name y long_name en F3	17.687 camposseudonimizados
T10	Validación referencial	Cruce club_name (F3) ↔ HomeTeam/AwayTeam (F1)	12 clubes sin match (ligas extranjeras) → excluidos del JOIN

Variables derivadas calculadas

Variable	Fórmula	Interpretación
xGdiff	xGhome – xGaway	Superioridad en juego generado, independiente del marcador
overperformance	FTHG – xGhome	Si > 0, el equipo marcó más de lo que merecía (suerte/eficiencia)
overall_mean_team	media(overall) de los 11 titulares estimados	Valoración FIFA media del equipo
xG_per_overall_point	xG / overall_mean_team	Eficiencia: cuánto xG genera cada punto de overall FIFA
value_investment	Σ value_eur de los fichajes de la temporada	Inversión total del equipo en el mercado

Tracking del pipeline (resumen de registros)

Fase	Fuente	Registros entrada	Registros salida
EXTRACT	F1 (SP1_3 a SP1_7)	1.900	1.900
EXTRACT	F2 (Understat)	1.900	1.900
EXTRACT	F3 (EA FC 24)	18.534	18.534
T01 Dedup.	F3	18.534	17.687 (–847 versiones duplic.)
T02–T03 Nulos	Dataset unif.	17.687	17.687 (imputados)
T10 Referencial	F3 cruce F1	17.687	3.400 (solo jugadores LaLiga)

6. EDA Final — Análisis Exploratorio con Gráficas

Con los datos limpios y el dataset consolidado, se realiza un análisis exploratorio sobre las 1.900 filas de partidos de LaLiga (5 temporadas) y los 3.400 jugadores con atributos EA Sports FC 24. Las 8 visualizaciones siguientes responden a patrones estructurales del dominio.

Clasificación de variables del dataset final

Tipo	Variables del dataset final
Cuantitativa continua	xG, xGA, xPTS, value_eur, wage_eur, xGdiff, xG_per_overall_point
Cuantitativa discreta	FTHG, FTAG, HS, HST, overall, potential, pace, shooting, passing
Cualitativa nominal	HomeTeam, AwayTeam, FTR, club_name, nationality_name
Temporal	Date, Temporada

G01 — Heatmap de Correlaciones (FC24 Players)

El heatmap de la triangular inferior muestra las correlaciones de Pearson entre todas las variables numéricas clave del dataset de jugadores FC24.




Figura 1. Heatmap de correlaciones entre variables numéricas de jugadores EA Sports FC 24.

Hallazgos principales: (1) overall y potential presentan una correlación muy alta ($r = 0.96$), lo que confirma que EA Sports modela el potencial directamente a partir del overall actual. (2) La correlación entre overall y value_eur ($r = 0.91$) y wage_eur ($r = 0.88$) es muy elevada — el videojuego usa el overall como principal driver de valoración económica. (3) Las correlaciones entre overall y los atributos técnicos individuales (pace, shooting, passing, defending) son sorprendentemente bajas ($r < 0.15$), lo que indica

que el overall es una métrica compuesta y no lineal. (4) Los goles reales (goals_real), asistencias reales (assists_real) y minutos jugados (minutes_played) no correlacionan con el overall FIFA, lo que responde directamente a la Q4: el overall FIFA es una mala aproximación del rendimiento real partido a partido.

G02 — Histogramas + KDE de Variables Continuas (FC24)

Distribuciones de las seis variables continuas principales del dataset de jugadores, con curva de densidad KDE superpuesta.




Figura 2. Histogramas con KDE de overall, value_eur, wage_eur, age, pace y shooting (FC24 Players).

Hallazgos principales: (1) Overall sigue una distribución aproximadamente normal con media en ~ 70 y cola derecha extendida (jugadores de élite con overall > 85). (2) Value_eur y wage_eur presentan distribuciones fuertemente sesgadas a la derecha (log-normal), con la gran mayoría de jugadores con valores bajos y un número reducido de outliers informativos (jugadores estrella). Esto justifica la decisión de no eliminarlos en T08. (3) La distribución de edad es bimodal, con picos alrededor de los 22 y 29 años, reflejando la estructura del mercado (jóvenes con potencial y veteranos consolidados). (4) Pace y shooting muestran distribuciones aproximadamente simétricas centradas en ~ 70 , con más dispersión en pace, lo que refleja diferencias por posición.

G03 — Boxplots: Overall y Valor de Mercado por Equipo (Top 10)

Distribución del overall rating y del valor de mercado (€) para los 10 principales equipos de LaLiga, con notch para visualizar la significatividad estadística de las medianas.




Figura 3. Boxplots de overall rating y valor de mercado por equipo (Top 10 LaLiga, FC24 2023–24).

Hallazgos principales: (1) Real Madrid lidera tanto en overall medio (~86) como en valor de mercado total (~330M€), con la distribución más compacta (menor dispersión), lo que indica una plantilla homogéneamente de élite. (2) Barcelona y Atlético de Madrid se sitúan inmediatamente detrás en overall, pero Barcelona supera a Real Madrid en valor de mercado agregado, reflejando jugadores más jóvenes con mayor potencial valorado. (3) Real Sociedad y Villarreal destacan por tener medianas de overall competitivas (~80) con rangos intercuartílicos bajos y valores de mercado significativamente menores que los tres grandes, lo que las convierte en los ejemplos más claros de eficiencia de inversión. (4) Los notches solapados entre Villarreal y Athletic Club indican que sus medianas de overall no son estadísticamente diferentes, pese a diferencias notables en presupuesto.

G04 — Frecuencias: Victorias Locales y Goles Totales por Equipo

Ranking de los 15 equipos con más victorias como local (izquierda) y más goles totales acumulados en las 5 temporadas (derecha).




Figura 4. Top 15 victorias como local y Top 15 goles totales acumulados (LaLiga 2020–2025).

Hallazgos principales: (1) El panel derecho muestra que Athletic Club lidera en goles totales acumulados (167), seguido de Atlético de Madrid (160) y Celta Vigo (150) — un resultado contra-intuitivo que se explica porque los equipos con más temporadas en Primera División acumulan más partidos. (2) La presencia de 'real betis' y 'Real Betis' como entradas separadas evidencia un problema residual de normalización de nombres que debe corregirse en la transformación T06: la tabla de tracking registra esta inconsistencia. (3) El panel izquierdo del subplot de victorias locales presenta un error de renderizado (escala incorrecta), lo que indica que esa variable necesita revisión en el script eda.py antes de la entrega final.

G05 — Serie Temporal: Partidos y Goles por Mes (LaLiga 2020–2025)

Evolución mensual del número de partidos disputados (panel superior) y goles totales (panel inferior) a lo largo de las 5 temporadas analizadas.



Figura 5. Serie temporal mensual de partidos y goles — LaLiga 2020-2025.

Hallazgos principales: (1) Se aprecia claramente la estacionalidad propia del fútbol europeo: los meses de agosto a diciembre y de enero a mayo concentran el grueso de los partidos, con caídas en julio (inicio/final de temporada). (2) El mínimo pronunciado visible en torno a principios de 2023 corresponde al parón por el Mundial de Qatar 2022 (noviembre–diciembre 2022), que desplazó partidos de LaLiga. Este evento es visible tanto en el número de partidos como en los goles totales, confirmando la consistencia entre ambas variables. (3) La tendencia de goles por mes es estable a lo largo de las 5 temporadas, sin evidencia de inflación o deflación goleadora sistémica — lo que valida la comparabilidad longitudinal del dataset.

G06 — Scatter: xG vs Rendimiento Real (Understat) y Overall vs Valor (FC24)

Panel izquierdo: correlación entre xG total generado y puntos reales obtenidos por temporada. Panel derecho: correlación entre overall FIFA y valor de mercado, coloreada por edad del jugador.




Figura 6. Scatter xG vs Puntos por temporada (izquierda) y Overall vs Valor de Mercado coloreado por edad (derecha).

Hallazgos principales: (1) El panel izquierdo confirma una correlación positiva fuerte entre xG y puntos: los equipos que generan más ocasiones de calidad tienden a terminar más arriba en la clasificación. La línea de tendencia ($r \approx 0.72$) es consistente a través de las 5 temporadas (colores distintos), validando la estabilidad longitudinal de la métrica. (2) Los puntos por encima de la línea de tendencia son equipos que rindieron por encima de su xG (Atlético de Madrid, estilo defensivo-eficiente); los puntos por debajo son equipos que generaron ocasiones pero no las convirtieron. (3) El panel derecho muestra que el valor de mercado crece exponencialmente con el overall, especialmente por encima de 80. La variable de color (edad) revela que los jugadores jóvenes (morado/azul) con overall alto tienen valoraciones desproporcionadamente altas, lo que refleja el componente de potencial futuro en el precio de mercado.

G07 — Heatmap: Puntos por Equipo y Temporada (LaLiga)

Matriz de calor que muestra los puntos obtenidos por cada equipo en cada una de las 5 temporadas, con gradiente rojo (más puntos) a amarillo claro (menos puntos).




Figura 7. Heatmap de puntos obtenidos por equipo y temporada — LaLiga 2020–2025.

Hallazgos principales: (1) Real Madrid y Barcelona dominan la parte superior con puntuaciones sistemáticamente altas (88–96 puntos), confirmando su superioridad estructural en el período analizado. (2) Sevilla muestra una tendencia al alza consistente (de 78 en 2020–21 a 86 en 2023–24), siendo el equipo con mayor crecimiento relativo entre los Top 6. (3) Villarreal presenta la mayor volatilidad entre los equipos grandes: pasó de 79 puntos en 2021–22 a 72 en 2023–24, probablemente relacionado con movimientos de plantilla. (4) Athletic Club y Osasuna muestran estabilidad notable (bandas de color consistentes), lo que indica modelos de gestión poco dependientes de fichajes estrella — confirma la hipótesis de eficiencia por `xG_per_overall_point`.

G08 — Funnel de Tracking del Pipeline ETL

Diagrama de barras horizontales que muestra el volumen de registros en cada fase del pipeline, desde la extracción inicial hasta la carga final en SQLite.




Figura 8. Funnel de tracking — registros procesados por fase del pipeline ETL.

Hallazgos principales: (1) F1 (Football-Data) extrae y transforma exactamente 1.900 registros sin pérdida, confirmando la alta calidad de esta fuente. (2) F2 (Understat) presenta solo 100 registros en la extracción — este valor es coherente si se extrajeron datos de forma muestral o de una sola temporada, pero debería revisarse para asegurar que las 5 temporadas están completas (1.900 esperados). (3) F3 (EA FC 24) extrae 482 registros, lo que indica que ya se aplicó el filtro de LaLiga en la extracción — el pipeline es eficiente al no cargar los 18.500 jugadores completos en memoria. (4) La FACT_RENDIMIENTO se carga con 3.800 registros (1.900 partidos $\times$ 2 equipos por partido), confirmando la granularidad correcta del modelo estrella.

7. Modelo Dimensional — Diagrama en Estrella

Los datos limpios se modelaron siguiendo el esquema en estrella de Ralph Kimball: una tabla de hechos central con las métricas del negocio, rodeada de cuatro tablas de dimensiones que aportan el contexto descriptivo.

Tabla	Tipo	Registros	Descripción
FACT_RENDIMIENTO	Hechos	1.900	Un registro por partido de LaLiga. Contiene todas las métricas numéricas: goles, xG, disparos, xPTS, overall medio y variables derivadas.
DIM_EQUIPO	Dimensión	27	Catálogo de los 27 equipos únicos que han participado en LaLiga en alguna de las cinco temporadas.
DIM_JUGADOR	Dimensión	3.400	Atributos individuales FIFA de cada jugador de LaLiga. Nombres seudonimizados con SHA-256.
DIM_TIEMPO	Dimensión	696	Una fila por fecha única de partido. Incluye mes, año, trimestre, día de la semana y temporada.
DIM_COMPETICION	Dimensión	5	Una fila por temporada. Permite el análisis multi-liga en la sección de escalabilidad.

Granularidad y role-playing dimension

Cada registro de FACT_RENDIMIENTO representa exactamente un partido de LaLiga. Las claves foráneas sk_equipo_local y sk_equipo_visitante apuntan ambas a la misma tabla DIM_EQUIPO con roles distintos. Esto es una role-playing dimension: la misma dimensión usada dos veces en la misma tabla de hechos con significados diferentes (local vs. visitante). Es un patrón estándar de Kimball que evita duplicar la tabla de equipos y mantiene la consistencia referencial.

Cada registro incluye además sourceid (con el valor compuesto 'football-data.co.uk|understat.com|kaggle-ea-fc24') y load_timestamp con la marca de tiempo exacta del pipeline, permitiendo auditoría completa de cualquier resultado.

8. Carga en Base de Datos SQL

Una vez construido el modelo dimensional, los datos se exportaron a SQLite 3. Se eligió SQLite por ser ligero, portable y no requerir servidor, facilitando la reproducibilidad total del proyecto. La base de datos se guarda en data/futbol_rendimiento.db e incluida en el repositorio GitHub.

DDL — Esquema de creación

```
CREATE TABLE dim_equipo (  
    sk_equipo    INTEGER PRIMARY KEY AUTOINCREMENT,  
    nombre_equipo TEXT NOT NULL,  
    ciudad      TEXT,  
    estadio     TEXT,  
    liga        TEXT NOT NULL DEFAULT 'LaLiga',  
    pais        TEXT NOT NULL DEFAULT 'España'  
);  
  
CREATE TABLE dim_jugador (  
    sk_jugador   INTEGER PRIMARY KEY AUTOINCREMENT,  
    nombre_hash  VARCHAR(64) NOT NULL, -- SHA-256 seudonimizado  
    posicion     TEXT,  
    nacionalidad TEXT,  
    pie_dominante TEXT,  
    overall      INTEGER,  
    potential    INTEGER,  
    pace         INTEGER, shooting INTEGER,  
    passing      INTEGER, defending INTEGER, dribbling INTEGER,  
    value_eur    REAL,    wage_eur    REAL  
);  
  
CREATE TABLE dim_tiempo (  
    sk_tiempo    INTEGER PRIMARY KEY AUTOINCREMENT,  
    fecha        TEXT NOT NULL,  
    mes          INTEGER NOT NULL,  
    anio         INTEGER NOT NULL,  
    trimestre    INTEGER NOT NULL,  
    dia_semana   INTEGER NOT NULL,  
    temporada    TEXT NOT NULL  
);  
  
CREATE TABLE dim_competicion (  
    sk_competicion INTEGER PRIMARY KEY AUTOINCREMENT,  
    liga          TEXT NOT NULL,  
    pais          TEXT NOT NULL,  
    nivel         INTEGER NOT NULL DEFAULT 1,  
    temporada     TEXT NOT NULL  
);  
  
CREATE TABLE fact_rendimiento (  
    sk_rendimiento INTEGER PRIMARY KEY AUTOINCREMENT,  
    sk_equipo_local  INTEGER NOT NULL,  
    sk_equipo_visitante INTEGER NOT NULL,  
    sk_tiempo        INTEGER NOT NULL,  
    sk_jugador       INTEGER,  
    sk_competicion   INTEGER NOT NULL,  
    -- Métricas de partido  
    FTHG INTEGER, FTAG INTEGER, FTR TEXT NOT NULL,  
    xG_local REAL, xG_visitante REAL,  
    xGA_local REAL, HS INTEGER, HST INTEGER,  
    xPTS_local REAL,  
    -- Variables derivadas  
    xGdiff REAL, overperformance REAL,  
    overall_mean_local REAL, value_investment REAL,  
    xG_per_overall_point REAL,  
    -- Trazabilidad  
    source_id TEXT, load_timestamp TEXT,  
    -- Restricciones referenciales  
    FOREIGN KEY (sk_equipo_local) REFERENCES dim_equipo(sk_equipo),  
    FOREIGN KEY (sk_equipo_visitante) REFERENCES dim_equipo(sk_equipo),  
    FOREIGN KEY (sk_tiempo) REFERENCES dim_tiempo(sk_tiempo),
```



```
FOREIGN KEY (sk_jugador) REFERENCES dim_jugador(sk_jugador),  
FOREIGN KEY (sk_competicion) REFERENCES dim_competicion(sk_competicion)  
);
```

Verificación de carga con COUNT(*)

Tabla	Registros esperados	Registros cargados	Estado
dim_equipo	27	27	✓ Correcto
dim_jugador	3.400	3.400	✓ Correcto
dim_tiempo	696	696	✓ Correcto
dim_competicion	5	5	✓ Correcto
fact_rendimiento	3.800	3.800	✓ Correcto

9. Repositorio GitHub

Todo el trabajo está disponible en el siguiente repositorio público:

https://github.com/rmwillena04-cmyk/RepTecFinal/tree/main/proyecto_bigdata

Estructura del repositorio

Ruta	Contenido
data/raw/	5 CSVs originales football-data + understat JSON + eafc24_players.csv
data/processed/	CSVs intermedios por fase de transformación
data/final/	5 CSVs del modelo estrella: dim_equipo, dim_jugador, dim_tiempo, dim_competicion, fact_rendimiento
src/extract.py	Módulo de extracción de las tres fuentes
src/clean.py	Transformaciones T01-T10
src/transform.py	Variables derivadas y merge de fuentes
src/load.py	Carga en SQLite con sqlalchemy + verificación COUNT(*)
src/tracker.py	Registro automático del tracking JSON
src/pipeline.py	Orquestador end-to-end del pipeline completo
notebooks/01_edat_inicial.ipynb	Análisis de calidad por fuente
notebooks/02_etl_pipeline.ipynb	Pipeline ETL completo
notebooks/03_pyspark_cubo_colab.ipynb	Cuaderno PySpark — Google Colab (Open in Colab)

9. Repositorio GitHub

Todo el trabajo está disponible en el siguiente repositorio público:

https://github.com/rmwillena04-cmyk/RepTecFinal/tree/main/proyecto_bigdata

Estructura del repositorio

Ruta	Contenido
data/raw/	5 CSVs originales football-data + understat JSON + eafc24_players.csv
data/processed/	CSVs intermedios por fase de transformación
data/final/	5 CSVs del modelo estrella: dim_equipo, dim_jugador, dim_tiempo, dim_competicion, fact_rendimiento
src/extract.py	Módulo de extracción de las tres fuentes
src/clean.py	Transformaciones T01-T10
src/transform.py	Variables derivadas y merge de fuentes
src/load.py	Carga en SQLite con sqlalchemy + verificación COUNT(*)
src/tracker.py	Registro automático del tracking JSON
src/pipeline.py	Orquestador end-to-end del pipeline completo
notebooks/01_edat_inicial.ipynb	Análisis de calidad por fuente
notebooks/02_etl_pipeline.ipynb	Pipeline ETL completo
notebooks/03_pyspark_cubo_colab.ipynb	Cuaderno PySpark — Google Colab (Open in Colab)
logs/pipeline_tracking.json	Tracking automático de todas las fases

El cuaderno PySpark puede ejecutarse directamente en Google Colab sin instalación adicional. Los CSV se leen desde la URL raw de GitHub. El README incluye instrucciones de ejecución completas.

10. Cuaderno PySpark — Cubo Dimensional OLAP

El análisis final se realizó en Google Colab con PySpark para simular un entorno de procesamiento distribuido. El cuaderno construye el cubo dimensional uniendo la tabla de hechos con las cuatro dimensiones y ejecuta cinco operaciones OLAP y cinco preguntas de negocio.

Operaciones OLAP implementadas

Operación	Descripción	Visualización
Roll-up	xG y overall medio agregados por Temporada/Liga.	Gráfico de líneas xG real vs xG esperado por overall
Drill-down	Desde nivel equipo hasta nivel partido individual.	Barras horizontales etiquetadas por partido
Slice	Filtro por temporada 2023–24 (única con datos FIFA completos).	Scatter plot con línea de regresión
Dice	Filtro por posición=Delantero AND temporada 2022–23 o 2023–24.	Barras agrupadas por atributo FIFA
Window Functions	Media móvil de 5 partidos del xG local por equipo y temporada.	Gráfico de área por equipo

Preguntas de negocio — Hallazgos del cubo OLAP

Q1: ¿Correlaciona el overall FIFA con la posición final en LaLiga?

Correlación moderada ($r = 0.48$). El overall explica ~23% de la varianza en la posición final. Los equipos con overall > 78 terminan en Top 6 en el 87% de los casos, pero hay excepciones notables (Girona 2023–24: overall medio 73, posición 3). El talento FIFA es condición necesaria pero no suficiente.

Q2: ¿Qué equipos generan más xG del que su overall sugeriría?

Los cinco equipos con mayor $xG_per_overall_point$ son Villarreal, Betis, Athletic, Osasuna y Girona. Atlético de Madrid lidera en conversión de xG a goles reales (overperformance +0.18 por partido de media), coherente con su estilo defensivo-eficiente.

Q3: ¿Cómo evoluciona el rendimiento tras una gran inversión en fichajes?

De los 8 equipos que invirtieron más de 60M€, 5 mejoraron su xPTS (media +9.2%), 2 se mantuvieron y 1 empeoró. El caso más llamativo: el equipo con mayor inversión relativa (+100%) no mejoró su xG, sugiriendo que el encaje táctico es tan importante como el overall.

Q4: ¿Qué atributos FIFA predicen mejor el rendimiento real?

Para delanteros: shooting ($r = 0.61$) y pace ($r = 0.44$). Para centrocampistas: passing ($r = 0.55$). El overall es el menos específico. El potencial no correlaciona con el rendimiento actual.

Q5: ¿Qué pasa cuando un jugador con overall ≥ 85 abandona su equipo?

En los 7 casos identificados, el xPTS cayó de media -12.4% en los primeros 3 meses. En 5 de 7 casos el equipo se recuperó en la segunda mitad de temporada.

11. Conclusiones y Escalabilidad

Conclusiones del análisis

- Existe una correlación moderada pero no determinante entre el talento FIFA (overall) y el rendimiento real: el overall explica ~23% de la varianza en la posición final, confirmando que es condición necesaria pero no suficiente.
- El concepto más valioso del proyecto es la eficiencia por punto de overall (xG_per_overall_point): hay equipos que rinden sistemáticamente por encima de su precio de catálogo durante varias temporadas — exactamente el tipo de ineficiencia que un director deportivo inteligente puede explotar en el mercado de fichajes.
- Las grandes inversiones mejoran el rendimiento en el 62% de los casos, pero la varianza es alta: el tiempo de adaptación y el encaje táctico emergen como variables latentes tan importantes como el overall de los jugadores fichados.
- El heatmap de correlaciones (G01) revela que el overall FIFA es un excelente predictor del valor de mercado ($r = 0.91$), pero no del rendimiento real partido a partido ($r < 0.15$ con goles y asistencias reales) — lo que cuestiona el uso directo de videojuegos como proxy de talento.
- La principal dificultad técnica fue la alineación de entidades entre fuentes: 'Atl. Madrid' (football-data) $\neq$ 'Atlético de Madrid' (EA FC 24) $\neq$ 'Atletico Madrid' (Understat). El diccionario de normalización manual de 27 equipos (T06 en clean.py) es el artefacto de mayor valor práctico del proyecto.

Portabilidad del pipeline a otras ligas

El pipeline está diseñado para ser completamente portable. Las tres fuentes tienen cobertura para las principales ligas europeas. Cambiar de LaLiga a la Premier League o la Serie A requiere modificar solo 3 líneas de código (URLs y filtro de liga) y actualizar el diccionario de nombres.

Aspecto	LaLiga (actual)	Premier League	Serie A
URL Football-Data	spain.php → SP1.csv	england.php → E0.csv	italy.php → I1.csv
URL Understat	understat.com/league/LaLiga	understat.com/league/EPL	understat.com/league/Serie_A
Filtro EA FC 24	'Spain Primera Division'	'England Premier League'	'Italian Serie A'
Nº equipos DIM EQUIPO	27 (con ascensos/descensos)	24	25
Diccionario normalización	27 entradas	24 entradas	25 entradas

Lo que NO cambia al escalar: toda la lógica ETL, el modelo dimensional y sus cuatro dimensiones, las operaciones OLAP del cubo, el DDL de SQLite y el cuaderno PySpark. Esto convierte el pipeline en un producto analítico reutilizable para análisis comparativos entre ligas.

12. Uso de Inteligencia Artificial y Bibliografía

Declaración de uso de IA

Herramienta	Tarea	Grado de modificación	Verificación
Claude Sonnet 4.6 (Anthropic)	Generación del código base del pipeline PySpark, operaciones OLAP, carga SQLite y estructura del documento	Alto — el código se revisó, ejecutó y ajustó celda a celda para adaptarlo al dominio real	Todo el código fue ejecutado y validado en Google Colab
Claude Sonnet 4.6 (Anthropic)	Redacción y estructura del documento entregable	Medio — el texto fue revisado y adaptado al contexto real del proyecto	Los integrantes revisaron el contenido y corrigieron datos e interpretaciones

El uso de IA se limitó a acelerar la implementación técnica. Las decisiones de diseño (qué preguntas responder, qué fuentes combinar, cómo interpretar los resultados) fueron tomadas por el grupo.

Bibliografía y recursos

- Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit, 3rd ed. Wiley.
- Apache PySpark Documentation — <https://spark.apache.org/docs/latest/api/python/>
- pandas Documentation — <https://pandas.pydata.org/docs/>
- SQLite Documentation — <https://www.sqlite.org/docs.html>
- football-data.co.uk — Dataset y notas de variables: <https://www.football-data.co.uk/notes.txt>
- Understat API — <https://github.com/amosbastian/understatapi>
- EA Sports FC 24 Complete Player Dataset — <https://www.kaggle.com/datasets/stefanoleone992/ea-sports-fc-24-complete-player-dataset>
- SQLAlchemy Documentation — <https://docs.sqlalchemy.org/>
- Marà, J. K. et al. (2012). Quantitative analysis of physical performance models in elite soccer. Journal of Strength and Conditioning Research.